ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Ngày nhận hồ sơ	
(Do CQ quản lý ghi)	

THUYẾT MINH
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN 2026

A. THÔNG TIN CHUNG

A1. Tên đề tài

- Tên tiếng Việt (IN HOA): NGHIÊN CỨU VÀ ĐỀ XUẤT KHUNG PHÁT HIỆN MỐI ĐE DỌA DAI DẲNG NÂNG CAO DỰA TRÊN TÍCH HỢP DỮ LIỆU ĐA NGUỒN VÀ NHẬN BIẾT NGỮ CẢNH.
- Tên tiếng Anh (IN HOA): RESEARCH AND DEVELOPMENT OF A CONTEXT-AWARE FRAMEWORK FOR ADVANCED PERSISTENT THREAT DETECTION THROUGH MULTI-SOURCE DATA INTEGRATION.

A2. Thời gian thực hiện

6 tháng (kể từ khi được duyệt).

A3. Tổng kinh phí

Tổng kinh phí: **1** triệu đồng, gồm

- Kinh phí từ Trường Đại học Công nghệ Thông tin: **1** triệu đồng

A4. Chủ nhiệm

Họ và tên: **Nguyễn Nhật Nguyễn** .

Ngày, tháng, năm sinh: **21/01/2005** . Giới tính (Nam/Nữ): **Nam** .

Số CCCD: **075205002593**; Ngày cấp: **11/04/2021**; Nơi cấp: **Cục Cảnh sát Quản lý hành chính về trật tự xã hội**

Mã số sinh viên: **23521047**

Số điện thoại liên lạc: **0979495838**

Đơn vị (Khoa): **Khoa Mạng Máy Tính & Truyền Thông**

Số tài khoản: **1040349438** Ngân hàng: **Vietcombank**

A5. Thành viên đề tài (kể cả CNĐT)

TT	Họ tên	MSSV	Khoa
1	Nguyễn Nhật Nguyễn	23521047	Khoa Mạng Máy Tính và Truyền Thông
2	Võ Ngọc Hoàng Lâm	23520839	Khoa Mạng Máy Tính và Truyền Thông

B. MÔ TẢ NGHIÊN CỨU

B1. Giới thiệu về đề tài

Advanced Persistent Threat (APT) là dạng tấn công có chủ đích, trong đó kẻ tấn công duy trì hiện diện trong hệ thống trong thời gian dài và thực hiện nhiều bước tấn công liên tiếp để đạt mục tiêu. Một nghiên cứu được công bố tại ACM CCS 2025 đã phân tích có 1.509 báo cáo kỹ thuật, 177 bài và ghi nhận 603 nhóm hacker trong suốt 10 năm [1]. Điều này cho thấy APT không phải mối đe dọa mang tính lý thuyết mà là một chuỗi chiến dịch có tổ chức, lặp lại và nhắm vào mục tiêu giá trị cao. Hậu quả của một chiến dịch APT không chỉ dừng lại ở thiệt hại tài chính trực tiếp mà còn ảnh hưởng đến uy tín tổ chức, an ninh quốc gia và chuỗi cung ứng.

Khác với một sự kiện tấn công đơn lẻ, một chiến dịch APT được tổ chức thành nhiều giai đoạn theo mô hình kill chain/MITRE ATT&CK [2], từ các bước trinh sát, xâm nhập đến duy trì hiện diện và đánh cắp dữ liệu. Các dấu vết bị phân tán trên nhiều thực thể trong hệ thống và trải dài theo thời gian. Vì vậy bài toán phát hiện tấn công APT không chỉ là nhận diện một sự kiện bất thường mà là liên kết đúng các dấu vết trong trạng thái rời rạc thành một chuỗi nguyên nhân - kết quả. Phần lớn nghiên cứu hiện nay khai thác dữ liệu theo từng nguồn riêng biệt: host telemetry (tiến trình, tập tin, registry) hoặc network telemetry (kết nối, lưu lượng). Host log thường thiếu ngữ cảnh về hạ tầng mạng/hạ tầng C2, còn network alert khó truy vết trực tiếp về tiến trình hay người dùng cụ thể - hai nguồn này về bản chất sẽ bổ khuyết cho nhau nhưng ít khi được kết hợp một cách có hệ thống.

Vấn đề thứ hai là quá tải cảnh báo (alert fatigue) đã được định lượng cụ thể trong vận hành thực tế lẫn trong các công trình nghiên cứu học thuật. Một khảo sát định tính với các phân tích viên SOC tại USENIX Security 2022 cho thấy tỉ lệ cảnh báo mà chính các phân tích viên đánh giá là dương tính giả có thể lên tới khoảng 99% [3], đây cũng là lý do các hệ thống chuyên biệt như NoDoze ra đời để xếp hạng độ khả nghi của cảnh báo dựa trên tần suất xuất hiện trong provenance graph thay vì xử lý từng cảnh báo độc lập [4]. Trong nhóm phương pháp dựa trên provenance graph cho APT, hiện tượng này cũng được ghi nhận cụ thể:

- threaTrace do sử dụng cơ chế lan truyền nhãn sang các node lân cận, đã đánh dấu tới 12.848 node là tấn công trên tập CADETS và 25.297 node trên tập THEIA (DARPA TC) và chúng đã vượt xa số lượng node tấn công thật theo ground truth. Theo phân tích lại của một nghiên cứu so sánh sau này [5].
- KAIROS là một hệ thống đạt recall 100% trên phần lớn benchmark DARPA vẫn ghi nhận precision giảm còn 0,75 ở ít nhất một kịch bản (E5-ClearScope). Điều này buộc nhóm tác giả phải bổ sung cơ chế tái huấn luyện dựa trên các

dương tính giả đã được xác nhận [6]. Điều này cho thấy ngay cả hệ thống SOTA hiện nay vẫn chưa loại bỏ hoàn toàn false positive chỉ bằng kiến trúc mô hình.

Vấn đề thứ ba nằm ở việc các nghiên cứu đang giả định rằng dữ liệu luôn trọn vẹn và không bị thiếu hụt. Đây là một rủi ro không chỉ tồn tại trên lý thuyết mà còn thực tế đang tồn tại: Majorczyk et al. (2025) chỉ ra rằng bản phát hành công khai của DARPA OpTC không có nhãn sự kiện chính thức và còn tồn tại lỗi trong dữ liệu log ở cả mức host và network, đồng thời đề xuất một quy trình hiệu chỉnh, gán nhãn lại và đánh giá tác động của các lỗi này lên hiệu năng các phương pháp học máy dựa trên đồ thị [10].

Khảo sát các công trình công bố trong giai đoạn 2023–2026 cho thấy các hướng tiếp cận phát hiện APT có thể chia thành ba nhóm chính được tóm tắt trong Bảng 1.

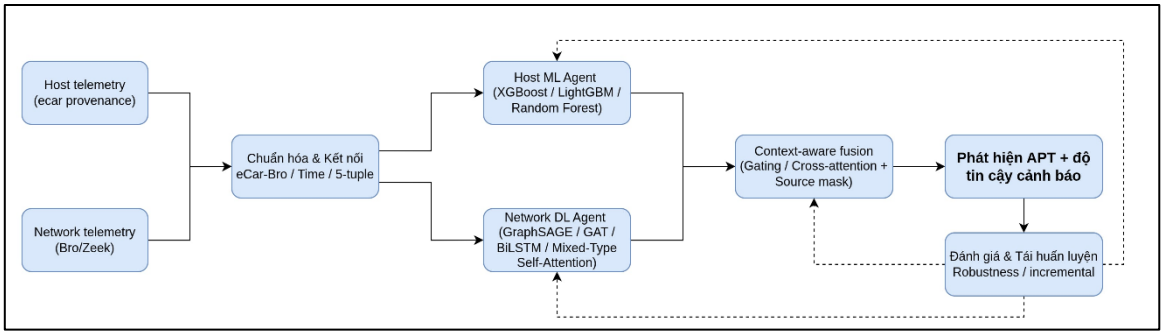
Bảng 1 Phân loại các hướng nghiên cứu phát hiện APT (2023–2026)

Phương pháp	Đại diện	Kết quả	Hạn chế
Rule-based	Smart-SIEM [11] Khung kết hợp GRR + auditbeat [12]	Smart-SIEM: bổ sung đặc trưng ngữ cảnh hành vi giúp F1 tăng từ ~0,705 lên 0,947–0,967[11]	Đánh giá độc lập từng sự kiện nên bỏ sót chiến dịch trinh sát kéo dài và phụ thuộc vào bộ luật cấu hình từ các chuyên gia.
Machine Learning	Ensemble Random Forest + XGBoost [13] Phân loại APT bằng RF/SVM/XGBoost/ DNN [14]	Đạt accuracy 97,1–99,9% và FPR 0,12–5,29% trên 4 bộ dữ liệu công khai (CSE-CIC-IDS2018, CIC-IDS2017, NSL-KDD, UNSW-NB15)	Chỉ dùng đặc trưng network-flow và không có provenance host. Các nghiên cứu chưa kiểm chứng trường hợp dữ liệu bị thiếu hụt và nhiễu.
Deep Learning	threaTrace [5] KAIROS [6] FLASH [7] TraceCluster [8] StageFinder [9]	threaTrace vượt 7 HIDS SOTA trên nhiều dataset công khai [5]. KAIROS recall 100% trên phần lớn benchmark DARPA [6]. TraceCluster nhanh hơn tới 37 lần so với baseline chậm nhất trên OpTC, vượt trội ở toàn bộ 9 kịch bản/4 dataset [8]. StageFinder đạt F1 0,96 và giảm 31% biến động dự đoán so với Cyberian/NetGuardian [9].	Phần lớn chỉ khai thác một nguồn (host provenance) và chưa khai thác nhánh network dẫn đến thiếu kiểm chứng về việc kết hợp đa nguồn dữ liệu.

Từ ba khoảng trống đã minh chứng ở trên, đề tài đặt câu hỏi nghiên cứu: Việc kết hợp cơ chế nhận biết ngữ cảnh (context-aware fusion) giữa host provenance và network telemetry có giúp (i) cải thiện Precision/F1 so với từng nguồn riêng lẻ hoặc phép ghép đặc trưng đơn giản (Simple Feature Fusion), đồng thời (ii) duy trì hiệu năng ổn định hơn khi một phần dữ liệu bị thiếu hoặc nhiễu so với các baseline ở Bảng 1 vốn chưa đánh giá tình huống này một cách có hệ thống?

Từ đó nhóm đề xuất một khung phát hiện APT dựa trên deep learning, trong đó host telemetry và network telemetry được mã hóa bởi các bộ mã hóa phù hợp với đặc trưng từng nguồn, sau đó được kết hợp bằng cơ chế context-aware fusion - có khả năng đánh giá mức độ hiện diện và độ tin cậy của từng nguồn dữ liệu thay vì sử dụng ghép đặc trưng đơn giản (Simple Feature Fusion) hoặc chỉ sử dụng một nguồn dữ liệu duy nhất. Khung phát hiện hướng tới hai mục tiêu: (i) Tăng độ chính xác và giảm dương tính giả nhờ đối chiếu chéo bằng chứng giữa dữ liệu của host và network; (ii) Duy trì khả năng phát hiện một cách ổn định khi một phần dữ liệu bị thiếu hoặc không đồng nhất giữa các nguồn - tình trạng rất phổ biến trong vận hành thực tế nhưng vẫn chưa có nhiều nghiên cứu tiến hành đánh giá một cách có hệ thống.

Về dữ liệu và môi trường thực nghiệm, đề tài sử dụng bộ dữ liệu DARPA Operationally Transparent Cyber (OpTC) [10]. Dữ liệu được thu thập từ các host SysClient trong môi trường mô phỏng doanh nghiệp và biểu diễn dưới dạng dữ liệu provenance theo mô hình eCAR, ghi nhận các thực thể và quan hệ liên quan đến tiến trình, tệp, kết nối mạng, người dùng và các hoạt động hệ thống. Trên cơ sở ground truth do bộ dữ liệu cung cấp, các sự kiện được ánh xạ về hai nhãn benign (0) và attack (1) để phục vụ quá trình huấn luyện và đánh giá mô hình.



Hình 1 Kiến trúc tổng quát mô hình học sâu phát hiện APT đa nguồn

B2. Mục tiêu, nội dung, kế hoạch nghiên cứu

B2.1 Mục tiêu

- Đề xuất khung phát hiện tấn công APT dựa trên học sâu tích hợp cơ chế dung hợp nhận biết ngữ cảnh (context-aware fusion) nhằm khai thác hiệu quả mối tương quan giữa hai nguồn dữ liệu host telemetry và network telemetry.

- Xây dựng quy trình tiền xử lý và liên kết dữ liệu đa nguồn trên tập dữ liệu DARPA OpTC, tập trung vào việc đồng bộ và ánh xạ chuỗi sự kiện giữa eCAR (host) và Bro/Zeek (network).
- Đánh giá định lượng hiệu năng phát hiện (Precision, F1, False Positive) của giải pháp đề xuất so với các baseline đơn nguồn (host-only, network-only) và phương pháp ghép nối đặc trưng trực tiếp đồng thời kiểm chứng độ bền của mô hình trong điều kiện dữ liệu bị khuyết thiếu hoặc nhiễu.
- Xây dựng hạ tầng thử nghiệm ảo hóa trên OpenStack nhằm kiểm chứng khả năng phát hiện, cách ly và hỗ trợ điều tra sự cố (DFIR - Digital Forensics and Incident Response) của khung đề xuất trong môi trường mô phỏng vận hành thực tế.
- Đánh giá khả năng tự thích ứng của mô hình trước các biến thể tấn công mới thông qua phương pháp học liên tục (continual learning) hướng tới giảm thiểu chi phí tái huấn luyện hoàn toàn.

B2.2 Nội dung và phương pháp nghiên cứu

Nội dung 1: Phân tích, tổng hợp và phân loại các loại APT và các kết quả nghiên cứu gần đây

- Mục tiêu:
    - Hệ thống hóa khái niệm, vòng đời và các nhóm hành vi thường gặp trong APT theo góc nhìn phát hiện dựa trên dữ liệu hệ thống.
    - Khảo sát các hướng provenance-based detection, network-based detection và multi-source/temporal learning nhằm làm rõ sự khác biệt về dữ liệu đầu vào, đơn vị phát hiện, khả năng truy vết và yêu cầu tính toán.
    - Xác định khoảng trống nghiên cứu mà đề tài tập trung: Giảm phụ thuộc vào dữ liệu đơn nguồn, kiểm soát false positive và duy trì khả năng phát hiện khi dữ liệu thiếu hoặc không đồng nhất.
- Phương pháp thực hiện:
    - Tổng quan có hệ thống các công trình tiêu biểu có liên quan và lập bảng so sánh theo loại telemetry, biểu diễn dữ liệu, mô hình học, dataset và chỉ số đánh giá.
    - Đối chiếu các công trình sử dụng rule-based (Smart-SIEM [11], khung IDS theo ATT&CK cho APT [12]), machine learning (ensemble RF/XGBoost [13,14]) và deep learning dựa trên provenance graph như THREATRACE, KAIROS, FLASH, TraceCluster [5,6,7,8] và hướng temporal multi-source như StageFinder [9] để xác định baseline phù hợp cho thực nghiệm ở Nội dung 3.

Nội dung 2: Đề xuất khung sử dụng deep learning để nhận biết và phân loại APT dựa trên tích hợp dữ liệu đa nguồn và nhận biết ngữ cảnh

- Mục tiêu:
  - Thiết kế kiến trúc logic gồm agent/collector nhẹ trên host, tầng xử lý network telemetry và thành phần phát hiện tập trung.
  - Xây dựng biểu diễn thống nhất để liên kết tiến trình, thực thể hệ thống và phiên mạng theo khóa tương quan, mốc thời gian và quan hệ nhân quả.
  - Đề xuất cơ chế context-aware fusion cho phép mô hình học mức đóng góp của từng nguồn, đồng thời sử dụng source mask hoặc reliability signal khi một nguồn bị thiếu.
- Phương pháp thực hiện:
  - Chuyển eCAR thành provenance graph với các thực thể process/file/registry/flow; chuẩn hóa Bro/Zeek thành chuỗi hoặc phiên kết nối với các đặc trưng mạng cần thiết.
  - Dùng eCAR-Bro làm lớp tương quan chính; kết hợp kiểm tra timestamp và 5-tuple để phát hiện liên kết bất thường hoặc thiếu khóa.
  - Khảo sát GNN/Temporal GNN cho nhánh host và BiLSTM/Transformer cho nhánh network; thử nghiệm gated fusion và cross-attention để lựa chọn cấu hình phù hợp với dữ liệu OpTC.

Nội dung 3: Đề xuất xây dựng và huấn luyện các mô hình học sâu trên DARPA OpTC

- Mục tiêu:
  - Xây dựng pipeline dữ liệu có thể tái lập, từ đọc dữ liệu, làm sạch, tạo graph/sequence đến sinh tập train, validation và test.
  - Thử nghiệm và lựa chọn kiến trúc mô hình phù hợp cho từng nhánh dữ liệu. Kiến trúc cụ thể (Graph Neural Network/Temporal GNN, LSTM/BiLSTM, hay Transformer) sẽ được xác định sau khi có kết quả so sánh thực nghiệm ban đầu, dựa trên các hướng đã được kiểm chứng trong tài liệu: GNN cho provenance graph [5,6,8], mô hình chuỗi/attention cho network telemetry và temporal reasoning [7,9].
  - Hạn chế data leakage giữa các giai đoạn thực nghiệm và xử lý mất cân bằng lớp để kết quả phản ánh đúng khả năng phát hiện APT.
- Phương pháp thực hiện:
  - So sánh GraphSAGE/GAT hoặc Temporal GNN cho host; so sánh BiLSTM và Transformer cho network, sau đó giữ cấu hình ổn định để đánh giá fusion.

o Ưu tiên chia tập theo host, scenario hoặc thời gian thay vì xáo trộn ngẫu nhiên từng record khi có thể và sử dụng class weighting hoặc focal loss nếu mất cân bằng ảnh hưởng rõ đến Recall/PR-AUC.

Nội dung 4: Thực nghiệm và đánh giá theo các kịch bản khác nhau

- Mục tiêu:

  o Đánh giá mức cải thiện thực tế của multi-source fusion so với từng nguồn riêng lẻ và so với phép ghép đặc trưng đơn giản.

  o Đánh giá độ bền của mô hình khi mất sự kiện, mất cạnh tương quan hoặc tạm thời thiếu một nguồn telemetry.

  o Xây dựng hạ tầng ảo hóa bằng OpenStack để triển khai môi trường cô lập nhằm mô phỏng luồng thu thập, phát hiện, tạo cảnh báo và hỗ trợ bước cách ly/điều tra theo quy trình chuẩn digital forensics

- Phương pháp thực hiện:

  o Dựng hạ tầng private cloud bằng OpenStack (Nova, Neutron, Cinder) để tạo các máy ảo mô phỏng endpoint văn phòng, máy chủ dịch vụ và cảm biến thu thập host/network telemetry; cô lập mạng thử nghiệm khỏi Internet và hệ thống thật bằng network segmentation/security group, chỉ cho phép giám sát nội bộ.

  o Triển khai kịch bản theo quy trình 5 bước, bám theo khung xử lý sự cố/forensics chuẩn của NIST [17] và và ánh xạ MITRE ATT&CK [2]:

  (1) Chuẩn bị và cô lập môi trường (Isolation) – snapshot toàn bộ máy ảo sạch trước khi thử nghiệm, tách hoàn toàn khỏi mạng ngoài

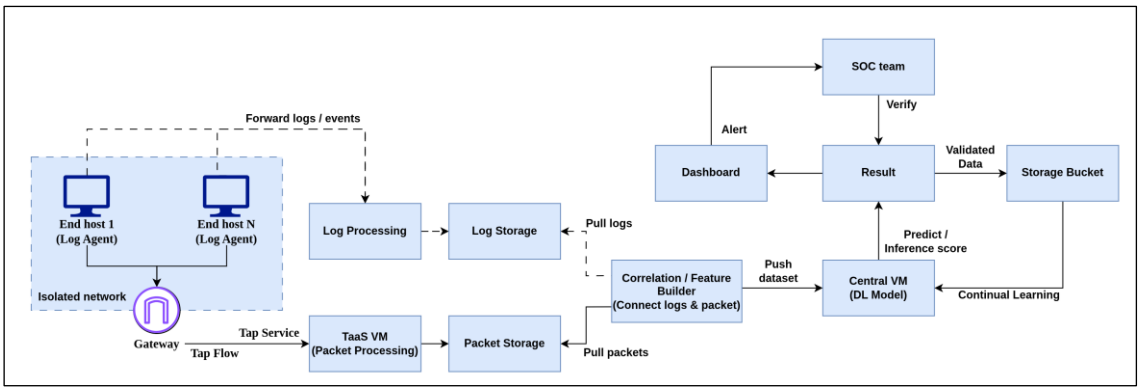
  (2) Lây nhiễm có kiểm soát bằng mẫu APT thực tế đã được gán nhãn/thu thập phục vụ nghiên cứu học thuật, hoặc công cụ mô phỏng hành vi đối kháng theo ATT&CK (Atomic Red Team/Caldera) khi cần giới hạn rủi ro vận hành, toàn bộ diễn ra trong mạng cô lập và được giám sát chặt bởi sensor host/network để sinh telemetry phục vụ đánh giá mô hình

  (3) Cách ly (Containment) tức thời máy bị ảnh hưởng khỏi phần còn lại của testbed ngay khi kịch bản kết thúc

  (4) Thu thập, bảo toàn log/artifact phục vụ phân tích forensics và đối chiếu với cảnh báo do mô hình sinh ra

  (5) Tiêu hủy (Secure teardown) toàn bộ máy ảo/snapshot chứa mẫu độc hại, khôi phục hạ tầng OpenStack về trạng thái sạch (golden image) cho vòng thử nghiệm tiếp theo.

- Sử dụng Precision, Recall, F1-score, PR-AUC, ROC-AUC và false-positive rate; bổ sung latency/throughput và mức sử dụng bộ nhớ khi đánh giá khả năng triển khai.
- Thực hiện ablation study với host-only, network-only, simple fusion và context-aware fusion; tạo các mức event/edge dropping có kiểm soát (ví dụ 10%, 20%, 30%) để đo độ suy giảm F1/PR-AUC.



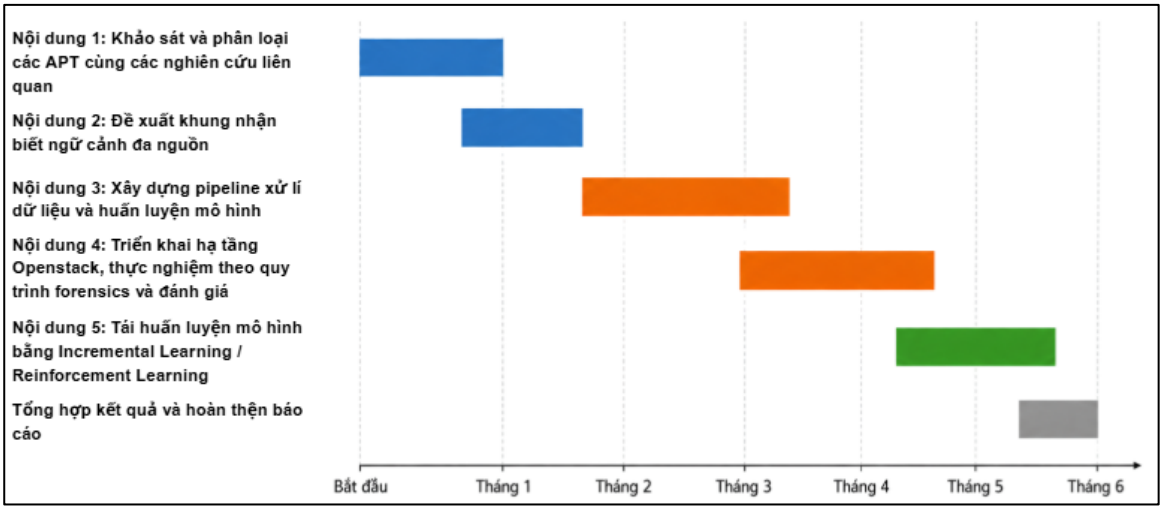
Hình 2 Kiến trúc tổng quát triển khai khung phát hiện APT đa nguồn

Nội dung 5: Tái huấn luyện và đánh giá khả năng thích ứng của mô hình

- Mục tiêu:
  - Khảo sát khả năng cập nhật mô hình khi dữ liệu mới đến theo thời gian hoặc khi chuyển sang scenario/host có phân bố khác hay scenario, mà không cần huấn luyện lại toàn bộ từ đầu.
  - So sánh chi phí và chất lượng giữa huấn luyện lại toàn bộ với fine-tuning/incremental learning có kiểm soát [15,16].
  - Đánh giá mức suy giảm trên dữ liệu cũ sau cập nhật và xác định quy trình tái huấn luyện phù hợp cho một hệ thống nguyên mẫu.
- Phương pháp thực hiện:
  - Chia dữ liệu theo cửa sổ thời gian hoặc scenario của OpTC để mô phỏng các đợt cập nhật; lưu một tập kiểm tra cố định để theo dõi hiện tượng quên kiến thức cũ.
  - Thực nghiệm incremental fine-tuning kèm replay buffer (giữ lại một phần dữ liệu cũ khi cập nhật), tham khảo hướng tiếp cận đã được kiểm chứng cho bài toán trôi dạt khái niệm (concept drift) trong phát hiện mã độc [15,16] hoặc thử nghiệm reinforcement learning để quyết định thời điểm và mức độ cập nhật mô hình dựa trên tín hiệu độ trôi dạt (drift) và chi phí cập nhật, thay vì cập nhật định kỳ cố định.
  - So sánh F1-score/PR-AUC, thời gian huấn luyện và mức chênh lệch hiệu năng trước – sau cập nhật.

B2.3 Kế hoạch nghiên cứu

Kế hoạch dưới đây được xây dựng cho thời gian thực hiện 6 tháng. Hai thành viên cùng tham gia toàn bộ các giai đoạn; phần phân công chính được nêu để bảo đảm mỗi hạng mục có người chịu trách nhiệm trực tiếp.



Hình 3 Kế hoạch nghiên cứu dự kiến trong 6 tháng tương ứng 5 nội dung nghiên cứu

B3. Kết quả dự kiến

- Báo cáo tổng quan và bảng phân loại các hướng phát hiện APT dựa trên provenance graph, network telemetry, temporal learning và tích hợp đa nguồn nhằm xác định rõ khoảng trống nghiên cứu và baseline sử dụng trong thực nghiệm.
- Khung phát hiện APT đa nguồn có nhận biết ngữ cảnh (context-aware fusion) cùng pipeline tiền xử lý và tương quan dữ liệu DARPA OpTC có khả năng tái lập, bao gồm bước làm sạch dữ liệu, xây dựng provenance graph, tạo network sequence/flow feature và ánh xạ eCAR-Bro.
- Mô hình phát hiện APT đa nguồn có nhận biết ngữ cảnh cùng các baseline host-only, network-only và simple fusion để so sánh.
- Bộ kết quả thực nghiệm thể hiện Precision, Recall, F1-score, PR-AUC, false-positive rate kèm ablation study để đánh giá độ bền dưới các mức thiếu dữ liệu/thiếu liên kết khác nhau và chi phí suy luận
- Hạ tầng thực nghiệm ảo hóa bằng OpenStack và quy trình đánh giá theo chuẩn digital forensics.
- Kết quả thực nghiệm tái huấn luyện/incremental learning và phân tích khả năng duy trì hiệu năng khi dữ liệu thay đổi theo thời gian hoặc scenario.
- Báo cáo khoa học, mã nguồn và tài liệu thực nghiệm được tổ chức ở mức có thể tái lập trong phạm vi cho phép của giấy phép dữ liệu và tài nguyên tính toán.

B4. Tài liệu tham khảo

[1] Yuldoshkhujaev, S., Jeon, M., Kim, D., Nikiforakis, N., & Koo, H. (2025). A decade-long landscape of advanced persistent threats: Longitudinal analysis and global trends. *Proceedings of the 2025 ACM SIGSAC Conference on Computer and Communications Security*, 3206–3220. https://doi.org/10.1145/3719027.3765085

[2] MITRE Corporation. (n.d.). *MITRE ATT&CK®*. https://attack.mitre.org/

[3] Alahmadi, B. A., Axon, L., & Martinovic, I. (2022). 99% false positives: A qualitative study of SOC analysts' perspectives on security alarms. In *31st USENIX Security Symposium (USENIX Security 22)* (pp. 2783–2800).

[4] Hassan, W. U., Guo, S., Li, D., Chen, Z., Jee, K., Li, Z., & Bates, A. (2019). NoDoze: Combatting threat alert fatigue with automated provenance triage. In *Proceedings of the Network and Distributed System Security Symposium (NDSS 2019)*.

[5] Wang, S., Wang, Z., Zhou, T., Sun, H., Yin, X., Han, D., Zhang, H., Shi, X., & Yang, J. (2022). THREATRACE: Detecting and tracing host-based threats in node level through provenance graph learning. *IEEE Transactions on Information Forensics and Security, 17*, 3972–3987.

[6] Cheng, Z., Lv, Q., Liang, J., Wang, Y., Sun, D., Pasquier, T., & Han, X. (2024). Kairos: Practical intrusion detection and investigation using whole-system provenance. In *2024 IEEE Symposium on Security and Privacy (SP)* (pp. 3533–3551).

[7] Rehman, M. U., Ahmadi, H., & Hassan, W. U. (2024). FLASH: A comprehensive approach to intrusion detection via provenance graph representation learning. In *2024 IEEE Symposium on Security and Privacy (SP)* (pp. 3552–3570).

[8] Xu, L., Zhao, Z., Zhao, D., Wang, Z., & Ge, C. (2026). TraceCluster: A lightweight and adaptive clustering-based subgraph attention network for APT detection in provenance graphs. *IEEE Transactions on Information Forensics and Security, 21*, 1065–1080.

[9] T. V. Phan and T. Bauschert, "Learning the APT kill chain: Temporal reasoning over provenance data for attack stage estimation," in *2026 IEEE International Conference on Communications (ICC)*, 2026, pp. 1–6, doi: 10.1109/ICC59461.2026.11588015.

[10] F. Majorczyk, B. Pilastre, and F. Dijoud, "A new hope for DARPA OpTC," in *2025 Annual Computer Security Applications Conference Workshops (ACSAC Workshops)*, 2025, pp. 551–561, doi: 10.1109/ACSACW69556.2025.00064.

[11] B. Alboushy, A. Jafar, M. Aljnidi, M. B. Disoki, and A. Shaheed, "Context-aware web attack detection in open-source SIEM systems via MITRE ATT&CK-enriched behavioral profiling," 2026, *arXiv:2605.13337*. [Preprint]. doi: 10.48550/arXiv.2605.13337.

[12] Park, N.-E., Lee, Y.-R., Joo, S., Kim, S.-Y., Kim, S.-H., Park, J.-Y., Kim, S.-Y., & Lee, I.-G. (2023). Performance evaluation of a fast and efficient intrusion detection framework for advanced persistent threat-based cyberattacks. *Computers & Electrical Engineering, 105*, 108548.

[13] Saini, N., Kasaragod, V. B., Prakasha, K., & Das, A. K. (2023). A hybrid ensemble machine learning model for detecting APT attacks based on network behavior anomaly detection. *Concurrency and Computation: Practice and Experience, 35*(28), e7865.

[14] N. Rani, B. Saha, and S. K. Shukla, "A comprehensive survey of automated Advanced Persistent Threat attribution: Taxonomy, methods, challenges and open research problems," *Journal of Information Security and Applications*, vol. 92, Art. no. 104076, 2025, doi: 10.1016/j.jisa.2025.104076.

[15] S. McFadden, M. Foley, M. D'Onghia, C. Hicks, V. Mavroudis, N. Paoletti, and F. Pierazzi, "DRMD: Deep reinforcement learning for malware detection under concept drift," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 40, no. 2, pp. 854–862, 2026, doi: 10.1609/aaai.v40i2.37053

[16] A. Sabbah, M. Kharma, M. Alkhanafseh, R. Jarrar, S. Zein, and D. Mohaisen, "Concept drift adaptation using self-supervised and reinforcement learning in Android malware detection," 2026, *arXiv:2605.24294*. [Preprint]. doi: 10.48550/arXiv.2605.24294.

[17] A. Nelson, S. Rekhi, M. Souppaya, and K. Scarfone, *Incident Response Recommendations and Considerations for Cybersecurity Risk Management: A CSF 2.0 Community Profile*, NIST SP 800-61 Rev. 3, Apr. 2025, doi: 10.6028/NIST.SP.800-61r3.

Ngày 27 tháng 08 năm 2026
Giảng viên hướng dẫn
(Ký và ghi rõ họ tên)



TS. Nguyễn Ngọc Tự

Ngày 27 tháng 08 năm 2026
Chủ nhiệm đề tài
(Ký và ghi rõ họ tên)



Nguyễn Nhật Nguyễn